Fréquence de sinistres en assurance auto

Qu'est-ce qui fait qu'un conducteur a plus de sinistres qu'un autre ?

Attuoman Prince Josias Koffi

1er octobre 2026

Projet de modélisation de la fréquence des sinistres en assurance automobile. Le rapport présente le nettoyage des données, la sélection des variables, la comparaison des modèles, la validation sur un échantillon de test et l'analyse des effets.

Qu'est-ce qui fait qu'un conducteur a plus de sinistres qu'un autre ?

Auteur : Attuoman Prince Josias Koffi

C'est la question de départ de ce projet. Je me mets à la place d'un assureur auto qui veut comprendre pourquoi le nombre de sinistres change d'une police à l'autre. Pour y répondre, j'ai construit un modèle qui prédit ce nombre à partir du contrat, du véhicule et du conducteur.

Ce rapport raconte mon cheminement : d'abord le grand ménage dans les données, ensuite la modélisation, puis ce que j'en retiens, y compris ce qui ne fonctionne pas parfaitement.

---

1. Remettre les données d'aplomb

Le point de départ

Je pars du fichier assurance_sale.csv, tiré du jeu public freMTPL2 (assurance auto, responsabilité civile, France). Il compte 682 122 lignes et 13 colonnes, et il a été abîmé exprès : formats mélangés, valeurs manquantes, doublons, valeurs impossibles. Mon premier travail a donc ressemblé à une enquête : repérer chaque problème, puis décider quoi en faire.

Je devais passer par Power BI pour cette étape. J'ai essayé, mais Power Query recalculait tout à chaque modification, et sur ce volume cela rendait le travail trop lent. J'ai donc fait la préparation en R (data.table), avec le script Prétraitement des données.Rmd. C'est un écart assumé par rapport à l'énoncé, et le script garde la trace de chaque décision.

Ce que j'ai trouvé, et ce que j'en ai fait

N°	Constat	Traitement	Lignes
1	Colonnes lues en texte	Lecture en character, typage explicite ensuite	682 122
2	ClaimAmount en formats très variés	Colonne supprimée (inutile pour la fréquence)	682 122
3	Préfixe POL0 sur l'identifiant	Préfixe supprimé	10 253
4	Manquants écrits de 5 façons ("", NA, N/A, ?, Inconnu)	Remplacés par NA	voir 13b et 13c
5	Casse, espaces et écritures multiples (zone, marque, région)	Majuscules, sans espaces ni tirets, préfixe R sur les régions	~20 700 / ~16 200 / ~5 100
6	Carburant : 14 écritures	Regroupées en 2 modalités (Essence, Diesel), plus « Inconnu » pour les manquants	~660 000
7	Virgule décimale	Conversion en nombre	682 122
8	Lignes strictement identiques	Doublons supprimés	2 698
9	Même police sur plusieurs lignes	Agrégation en une ligne par police (sinistres et expositions sommés), colonne nb_lignes_sources	1 411 polices
10	Valeurs impossibles	Remplacées par NA, ligne conservée	voir ci-dessous
11	Exposition ≤ 0	Remplacée par NA, lignes exclues (13a)	4 180
12	Exposition > 1 (de 1,01 à 3,00)	Lignes exclues	3 614
13a	Exposition manquante	Lignes supprimées	4 180
13b	Numériques manquants	Imputation par la médiane, colonne ligne_imputee	voir ci-dessous
13c	Catégoriels manquants	Modalité « Inconnu »	2 019 / 20 748 / 10 186 / 6 541
14	Plus de 5 sinistres	Lignes exclues	7

N°	Constat	Traitement	Lignes
15	Besoin de tranches	Variables numériques découpées en tranches, dans le script pour le modèle et recréées en colonnes calculées dans Power BI pour le tableau de bord (sauf la puissance, affichée sans tranches)	

Les valeurs impossibles (étape 10). Un véhicule d'âge négatif ou de 100 ans et plus (7 465 lignes), un conducteur de moins de 18 ans ou de plus de 100 ans (3 690), une puissance nulle, négative ou supérieure à 20 (1 475), un bonus-malus sous 50 ou au-dessus de 230 (3 124), une densité nulle, négative ou supérieure à 30 000 (1 981). Je les ai remplacées par NA et gardé la ligne, car le reste de la ligne reste utile.

Ce que j'ai imputé (étape 13b). Puissance : 4 097 lignes. Âge du véhicule : 31 880. Âge du conducteur : 10 170. Bonus-malus : 7 414. Densité : 7 425. Au total, 94 511 lignes (14,1 %) ont au moins une valeur imputée.

Les décisions qui comptent vraiment

Doublons et fusion. Les doublons exacts, j'ai simplement supprimé. Pour les polices présentes sur plusieurs lignes, j'ai additionné sinistres et expositions. Je reste prudent sur ce point : ces lignes sont peut-être une ligne d'origine et une copie modifiée, auquel cas les sinistres de ces polices seraient gonflés. Je le teste en partie 7.

Exposition supérieure à 1 an : j'ai exclu ces lignes. Mon premier réflexe a été de plafonner à 1. Puis j'ai regardé de plus près : ces lignes ont le nombre de sinistres d'une police à environ 0,5 an (0,054 sinistre par ligne). Plafonner à 1 aurait ajouté environ 1 700 années d'exposition qui n'existent pas et créé un groupe à fréquence artificiellement basse (0,054 contre 0,105). J'ai aussi testé l'idée d'une faute de frappe (1,35 pour 0,35). Elle ne tient pas : entre 1,00 et 1,30, on observe 32 sinistres alors qu'on en attendrait environ 2,5. Comme je ne trouvais aucune règle de correction fiable, j'ai préféré exclure ces lignes (0,5 % du fichier).

Plus de 5 sinistres : exclusion. Avec une fréquence moyenne d'environ 0,10, avoir plus de 5 sinistres en un an est quasi impossible (de l'ordre de 10^{-9}). Il s'agit très probablement d'erreurs, et seules 7 polices sont concernées.

Imputation par la médiane. Je l'ai choisie parce qu'elle résiste aux valeurs extrêmes (la densité et l'âge du véhicule sont très asymétriques) et qu'elle donne des valeurs entières. Elle a un défaut : elle réduit la variance et ignore les liens entre variables. Il y a aussi un effet à connaître : la médiane du bonus-malus vaut 50, la meilleure classe, donc les lignes sans bonus-malus se retrouvent dans cette classe. La fréquence est de 0,105 sans imputation contre 0,100 avec. La colonne ligne_imputee me permet de mesurer l'effet (partie 7).

Manquants textuels : modalité « Inconnu ». Je ne voulais ni perdre de lignes ni inventer une valeur.

Les tranches

Je les ai définies à partir des fréquences observées pendant l'exploration, en vérifiant que chaque classe garde assez d'exposition.

Variable	Tranches	Pourquoi
Âge du conducteur	18-21, 22-25, 26-30, 31-40, 41-50, 51-70, 71 et +	Les jeunes se distinguent (0,229), fréquence plate après 30 ans
Âge du véhicule	0, 1-3, 4-10, 11-15, 16 et +	Pic à 0 an (0,316), baisse au-delà de 15 ans (0,068)
Bonus-malus	50, 51-60, 61-80, 81-100, 101 et +	57 % des polices à 50, puis hausse rapide
Densité	1-50, 51-200, 201-1 000, 1 001-4 000, 4 001-10 000, plus de 10 000	Hausse régulière de 0,085 à 0,144
Puissance	4 et moins, 5, 6, 7, 8, 9-10, 11 et +	Effet irrégulier, valeurs rares regroupées
Exposition	jusqu'à 0,05 an, 0,05 à 0,3, 0,3 à 0,99, 1 an	Montre la hausse de fréquence sur les expositions courtes

Combien de lignes ai-je perdues ?

Étape	Lignes restantes	Lignes retirées
Fichier brut	682 122	
Après suppression des doublons exacts	679 424	2 698
Après fusion par police	678 013	1 411
Après exclusion des expositions supérieures à 1	674 399	3 614
Après exclusion des expositions manquantes ou nulles	670 219	4 180
Après exclusion des polices à plus de 5 sinistres	670 212	7

Au total, 11 910 lignes sont retirées, soit environ 1,7 % du fichier brut. Je trouve ce chiffre rassurant : le nettoyage a été sérieux sans abîmer le jeu de données.

Le fichier qui sert au modèle

Polices	Sinistres	Exposition (années)	Fréquence
670 212	37 014	355 362	0,1042

La fréquence, c'est le nombre de sinistres divisé par l'exposition : environ 0,10 sinistre par an et par police. Et 94,8 % des polices n'ont aucun sinistre, ce qui explique pourquoi la suite est délicate.

Pour juger honnêtement le modèle, je mets de côté 30 % des polices (le test) et je ne les utilise pas pour construire le modèle. Les choix de modélisation, notamment les modalités de référence, sont faits sur les 70 % restants. Le nettoyage, les exclusions et l'imputation ont été réalisés avant le découpage. Le tirage est aléatoire, avec une graine fixée (2026) pour retrouver les mêmes résultats.

Ce que l'exploration m'a appris

Variable	Constat	Fréquence
Zone	Hausse régulière de A (rural) à F (très dense)	0,084 à 0,144
Bonus-malus	Variable la plus discriminante	0,083 (50) à 0,38 (101 et +)
Âge du conducteur	Jeunes nettement plus risqués	0,229 (18-21 ans), environ 0,10 après 30 ans
Âge du véhicule	Pic à 0 an, baisse au-delà de 15 ans	0,316 (0 an), 0,068 (16 ans et +)
Carburant	Presque sans effet	0,101 (Diesel), 0,106 (Essence)
Puissance	Irrégulière, sans tendance	0,088 à 0,120
Durée d'exposition	Plus forte sur les expositions courtes	1,08 (jusqu'à 0,05 an), 0,072 (1 an)

Une ligne m'a particulièrement intrigué : la fréquence grimpe à 1,08 sur les expositions très courtes. J'y reviens plus loin, car c'est elle qui a le plus orienté la modélisation.

---

2. Le choix du modèle

Les contrats n'ont pas tous été observés pendant la même durée. Un contrat suivi six mois a moins de temps pour avoir un sinistre qu'un contrat suivi un an. Pour en tenir compte, j'utilise une régression de Poisson avec log(exposition) en offset : un contrat observé deux fois plus longtemps a alors deux fois plus de sinistres attendus. Les coefficients se lisent ensuite comme des effets multiplicatifs sur la fréquence annuelle.

---

3. Quelles variables garder ?

Comment je représente les variables

Je découpe les variables numériques en tranches, choisies d'après les fréquences observées à l'exploration. Cela permet de garder les effets qui ne sont pas linéaires. Par exemple, les véhicules neufs ont une fréquence très élevée (0,316 à 0 an), ce qu'une simple droite aurait écrasé.

Pour chaque variable, la modalité de référence est celle qui concentre le plus d'exposition dans l'échantillon d'apprentissage.

Zone ou densité : il faut choisir

La zone et la densité racontent presque la même chose. Je n'en garde qu'une, celle qui a le plus petit AIC.

Variable	AIC
zone_densite	201 275
tranche_densite	201 290

Je garde la zone. L'écart est faible (15), mais il suffit pour trancher.

La sélection, variable par variable

Je pars d'un modèle complet : âge du conducteur, âge du véhicule, bonus-malus, zone, puissance, carburant, marque et région. Puis je retire chaque variable une par une et je regarde ce que ça change (test du rapport de vraisemblance). Je la garde si le test est significatif à 1 % et si l'AIC augmente quand je la retire.

Variable	Degrés de liberté	LRT	Hausse de l'AIC
Âge du véhicule	4	3 226,7	3 218,7
Bonus-malus	4	2 691,6	2 683,6
Âge du conducteur	6	507,7	495,7
Puissance	6	205,1	193,1
Zone	6	119,4	107,4
Région	22	121,9	77,9
Marque	11	87,0	65,0
Carburant	2	22,4	18,4

Les 8 variables restent. Le carburant est la plus fragile du lot.

Une précision pour rester honnête : cette sélection a été faite avec le Poisson simple, dont la dispersion est de 2,07. Les tests sont donc un peu trop généreux. J'ai vérifié en divisant chaque LRT par 2,07, et tout reste significatif. Pour le carburant, cela donne 22,4 / 2,07 = 10,8 pour 2 degrés de liberté, soit une p-valeur d'environ 0,005.

---

4. Le modèle colle-t-il vraiment aux données ?

Avant de faire confiance à un modèle, je regarde trois choses :

- la surdispersion. En Poisson, la variance doit être égale à la moyenne ;
- les polices sans sinistre. Combien le modèle en prévoit, contre combien il y en a vraiment ;
- la durée d'observation. À l'exploration, la fréquence était bien plus haute sur les expositions très courtes (1,08 jusqu'à 0,05 an, contre 0,072 à 1 an). Or l'offset suppose que la fréquence ne dépend pas de la durée. Je teste donc log(exposition) comme variable en plus.

Je compare quatre modèles sur l'apprentissage.

Modèle	AIC	Dispersion	Zéros prévus (observés : 444 671)
Poisson	200 939	2,069	444 506
Poisson + log(expo)	195 962	1,059	444 213
Binomiale négative	200 590	2,009	445 019

Modèle	AIC	Dispersion	Zéros prévus (observés : 444 671)
Binomiale négative + log(expo)	195 736	1,029	444 666

Mon choix : binomiale négative + log(exposition), qui a le plus petit AIC.

Voici ce que j'en tire :

- La surdispersion ne venait pas d'abord de la forme de la loi, mais de l'hypothèse selon laquelle les sinistres augmentent proportionnellement à la durée. Ajouter log(exposition) fait baisser l'AIC de près de 5 000 et la dispersion de 2,07 à 1,06. C'est la découverte la plus utile de tout le projet.
- La binomiale négative seule change peu de chose (AIC -349). Une fois combinée à log(exposition), elle gagne encore 226 d'AIC et retrouve presque exactement le nombre de zéros : 444 666 prévus pour 444 671 observés.

Un point à garder en tête : le coefficient de log(exposition) n'est pas un effet d'assurance. Il corrige une anomalie des données, puisque les expositions courtes ont plus de sinistres par année que les longues. J'y reviens en partie 6.

---

5. Que vaut la prédiction sur des données jamais vues ?

Les indicateurs globaux

Indicateur	Valeur
Sinistres observés (test)	11 138
Sinistres prévus (test)	11 053
Observé / prévu	1,008
Gain de déviance, test	8,2 %
Gain de déviance, apprentissage	8,1 %

Sur le test, le modèle prévoit 11 053 sinistres pour 11 138 observés. Il sous-estime donc le total de moins de 1 %.

Le gain de déviance compare mon modèle à une prédiction naïve, qui donnerait la même fréquence moyenne à tout le monde. Il est de 8,2 % sur le test et de 8,1 % sur l'apprentissage. Avant de prédire, j'écarte du test les polices dont une modalité n'apparaît jamais à l'apprentissage, car le modèle ne peut pas estimer un effet pour cette modalité. Les gains de déviance sont très proches entre apprentissage et test, sans écart important entre les deux.

Un gain de 8 % peut paraître faible, mais il est normal dans ce contexte. 95 % des polices n'ont aucun sinistre, et un sinistre est en grande partie une affaire de hasard. Le modèle ne dit pas qui aura un sinistre. Il classe les polices selon leur niveau de risque, et c'est ce que l'on attend de lui en assurance.

Les groupes de risque

Je coupe le test en 10 groupes de même taille (environ 20 100 polices chacun) selon la fréquence prévue, puis je compare la fréquence prévue à la fréquence observée.

Groupe	Exposition	Sinistres observés	Sinistres prévus	Fréquence observée	Fréquence prévue
1	18 933	836	878	0,0442	0,0463
2	18 072	1 126	1 100	0,0623	0,0609
3	17 076	1 226	1 214	0,0718	0,0711
4	15 059	1 316	1 249	0,0874	0,0830
5	11 865	1 231	1 191	0,1038	0,1004
6	9 284	1 260	1 178	0,1357	0,1269
7	6 866	1 114	1 139	0,1622	0,1659
8	4 756	1 033	1 082	0,2172	0,2276

Groupe	Exposition	Sinistres observés	Sinistres prévus	Fréquence observée	Fréquence prévue
9	3 097	940	1 043	0,3035	0,3369
10	1 401	1 056	978	0,7537	0,6977

La fréquence observée monte à chaque groupe, de 0,044 à 0,754. Le groupe le plus risqué a environ 17 fois plus de sinistres par année que le moins risqué. Le modèle sait donc bien séparer les bons risques des mauvais.

Les fréquences prévues suivent les observées de près. L'écart est d'environ 5 % ou moins pour les groupes 1 à 5, 7 et 8. Trois groupes s'écartent plus nettement :

- le groupe 6 est sous-estimé d'environ 6 % ;
- le groupe 9 est surestimé d'environ 11 % (0,337 prévu pour 0,304 observé) ;
- le groupe 10 est sous-estimé d'environ 7 % (0,698 prévu pour 0,754 observé).

Un détail m'a fait réfléchir : l'exposition diminue d'un groupe à l'autre, de 18 933 années pour le groupe 1 à 1 401 pour le groupe 10. Cela vient du terme log(exposition), qui fait monter la fréquence prévue quand la durée est courte. Les groupes les plus risqués contiennent donc beaucoup de polices à exposition courte. Autrement dit, le classement reflète en partie la durée d'observation, et pas seulement les caractéristiques du conducteur et du véhicule.

Le modèle est-il bien calé selon la durée d'exposition ?

Je compare les sinistres observés aux sinistres prévus par tranche d'exposition (un rapport observé / prévu égal à 1 signifie que le modèle est bien calé).

Tranche d'exposition	Apprentissage, Poisson simple	Apprentissage, modèle retenu	Test, modèle retenu
Jusqu'à 0,05 an	6,91	1,44	1,35
0,05 à 0,3	1,77	0,91	0,96
0,3 à 0,99	0,89	0,97	0,98
1 an	0,84	1,06	1,05

Le terme log(exposition) corrige l'essentiel du défaut. Le Poisson simple sous-estimait de 6,9 fois les expositions les plus courtes. Mon modèle les sous-estime encore de 35 % sur le test (44 % sur l'apprentissage). La correction est donc nette, mais elle n'est pas complète pour les contrats de moins de 0,05 an (environ 7 % des polices du test, 425 sinistres observés).

---

6. Ce que chaque variable change au risque

Les résultats sont des rapports de fréquence par rapport à une modalité de référence, toutes choses égales par ailleurs. Un rapport de 1,50 veut dire 50 % de sinistres en plus. Un rapport de 0,80 veut dire 20 % en moins.

Le profil de référence dans l'apprentissage (rapport = 1) : un conducteur de 51 à 70 ans, avec un véhicule de 4 à 10 ans, un bonus-malus de 50, en zone C, avec une puissance de 6, roulant à l'essence, de marque B1 et habitant la région R24.

Un rapport dont l'intervalle de confiance à 95 % contient 1 n'est pas significativement différent de la référence.

Les effets les plus forts

Le bonus-malus. C'est le plus fort, et il grimpe à chaque classe.

Tranche	Rapport	Variation
50 (référence)	1	
51-60	1,26	+26 %
61-80	1,75	+75 %
81-100	2,09	+108 %

Tranche	Rapport	Variation
101 et +	4,72	+372 %

L'âge du véhicule.

Tranche	Rapport	Variation
0 an	2,36	+136 %
1-3 ans	0,89	-11 %
4-10 ans (référence)	1	
11-15 ans	0,85	-15 %
16 ans et +	0,65	-35 %

Un véhicule neuf a 2,4 fois plus de sinistres qu'un véhicule de 4 à 10 ans. Ensuite, la fréquence baisse avec l'âge.

L'âge du conducteur.

Tranche	Rapport	Variation	Significatif
18-21 ans	0,97	-3 %	non
22-25 ans	0,75	-26 %	oui
26-30 ans	0,64	-36 %	oui
31-40 ans	0,74	-26 %	oui
41-50 ans	1,02	+2 %	non
51-70 ans (référence)	1		
71 ans et +	1,15	+15 %	oui

Les 26-30 ans sont ceux qui ont le moins de sinistres. Les 71 ans et plus en ont 15 % de plus que les 51-70 ans.

Les 18-21 ans m'ont surpris : on ne les distingue pas de la référence, alors que leur fréquence brute était la plus haute (0,229). Les autres variables du modèle, notamment le bonus-malus, peuvent expliquer une partie de cet écart. Je ne peux pas l'établir à partir de ce modèle seul.

Les effets moyens ou faibles

La zone. La fréquence monte avec la densité, de -8 % en zone A à +18 % en zone F par rapport à la zone C. Les zones B (-3 %) et « Inconnu » (+5 %) ne sont pas significatives.

Zone	A	B	C (réf.)	D	E	F
Rapport	0,92	0,97	1	1,09	1,10	1,18

La puissance. Pas de tendance claire. Par rapport à la puissance 6, les écarts vont de -24 % (puissance 8) à +7 % (9-10).

Le carburant. Les véhicules diesel ont 8 % de sinistres en moins que les véhicules essence (0,92). L'effet est faible, mais significatif.

La marque. Presque aucune marque ne se distingue de B1. Seule B5 est un peu au-dessus (+8 %). B14 est en dessous (-19 %), mais l'intervalle est large et frôle 1.

La région. Les écarts les plus nets par rapport à R24 sont R83 (-31 %), R23 (-28 %), R41 (-26 %) et R91 (-25 %). Pour les régions rares (R21, R42, R43, R74, R94), les intervalles sont larges et contiennent 1 : je ne peux pas conclure.

Le coefficient de log(exposition)

Son rapport vaut 0,551 (intervalle de 0,543 à 0,559). Ce n'est pas un effet d'assurance : il corrige l'anomalie des données décrite en partie 4. Avec ce terme, les sinistres attendus varient comme l'exposition à la puissance 0,40 environ. Un contrat observé deux fois plus longtemps a donc environ 1,3 fois plus de sinistres, et non 2 fois. Pour une prévision à un an, ce terme disparaît (log 1 = 0).

Un exemple concret

Prenons un conducteur de 26-30 ans (0,64), avec un bonus-malus de 50 et un véhicule de 4 à 10 ans. Sa fréquence vaut 0,64 fois celle du profil de référence, soit environ 36 % de moins.

---

7. Mes choix de nettoyage changent-ils les conclusions ?

Deux décisions du nettoyage étaient discutables : l'imputation par la médiane et la fusion des polices présentes sur plusieurs lignes. Pour savoir si elles pesaient sur le résultat, j'ai refait le modèle sans les lignes imputées, puis sans les polices fusionnées, et j'ai regardé si les rapports bougeaient. Voici les 10 plus gros écarts.

Coefficient	Final	Sans imputées	Sans fusion	Écart max (%)
Bonus-malus 101 et +	4,716	4,932	4,714	4,6
Marque B13	1,060	1,102	1,060	4,0
Région R43	0,813	0,781	0,813	4,0
Région R21	1,046	1,009	1,047	3,5
Marque B11	1,035	1,071	1,035	3,5
Marque B10	0,982	1,011	0,983	3,0
Région R11	0,843	0,822	0,843	2,5
Région R22	0,927	0,905	0,927	2,4
Âge conducteur 22-25	0,745	0,729	0,746	2,2
Région R52	0,905	0,888	0,906	1,9

Le plus gros écart est de 4,6 %, sur le bonus-malus de 101 et plus. Aucun écart ne change le sens d'un effet.

- Sans les polices fusionnées, les rapports bougent à peine. Elles ne sont que 1 411 sur 670 212, donc le choix de les additionner n'a pas d'effet visible.
- Sans les lignes imputées, les écarts sont un peu plus grands, surtout pour les modalités rares (marques B13 et B11, régions R43 et R21). Mais on perd 14 % des données et l'estimation devient plus bruitée.

Mes conclusions tiennent donc, malgré l'imputation par la médiane.

---

8. Mettre tout ça en images avec Power BI

Le tableau de bord compte cinq pages, alimentées par deux sources non reliées entre elles.

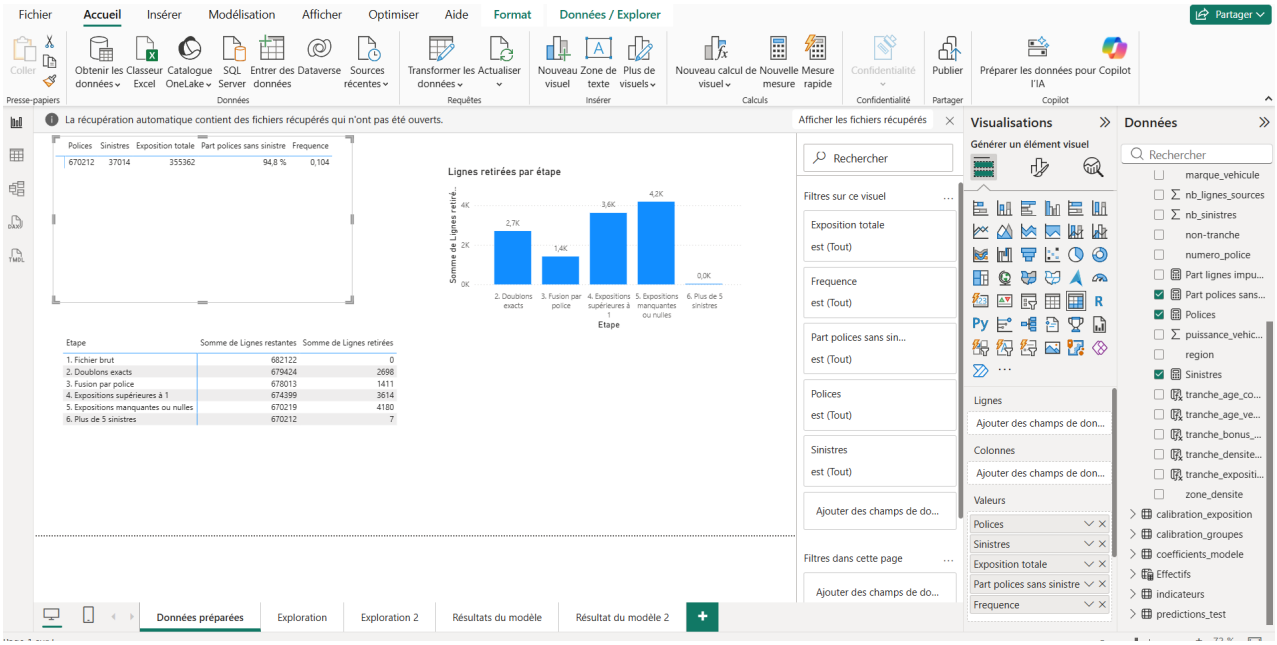
Page	Contenu	Source
Données préparées	Indicateurs (670 212 polices, 37 014 sinistres, 355 362 années, 94,8 % sans sinistre, fréquence 0,104) et lignes retirées par étape	assurance_propre, effectifs
Exploration	Fréquence par bonus-malus, âge du conducteur, âge du véhicule, zone, exposition et carburant	assurance_propre
Exploration 2	Puissance, marque, région, classes de sinistres (0, 1, 2, 3 et plus)	assurance_propre
Résultats du modèle	Observé / prévu (1,008), gains de déviance (8,2 et 8,1), rapports et intervalles par modalité avec segment de variable, courbe observé / prévu selon l'exposition	coefficients_modele, calibration_exposition, indicateurs
Résultat du modèle 2	Calibration par groupe de risque	calibration_groupes

J'ai recontrôlé les valeurs affichées sur le tableau de bord : fréquence de 0,083 à 0,383 selon le bonus-malus, 0,231 pour les 18-21 ans, 0,321 pour les véhicules neufs et 0,068 à 16 ans et plus.

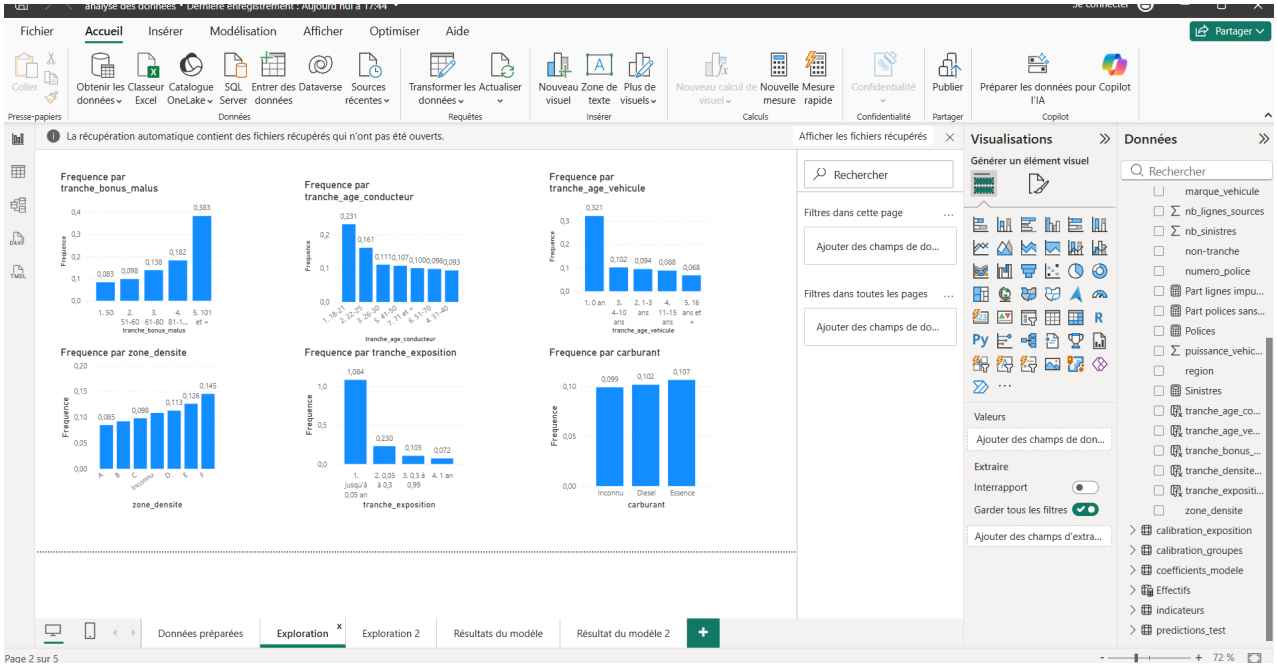
Ces valeurs sont très légèrement différentes de celles de la partie 1 (par exemple 0,231 contre 0,229 pour les 18-21 ans, 0,321 contre 0,316 pour les véhicules neufs, 0,085 à 0,145 contre 0,084 à 0,144 pour les zones, 0,102 et 0,107 contre 0,101 et 0,106 pour le carburant). Les chiffres d'exploration de la partie 1 sont calculés sur le fichier nettoyé complet, tout comme le tableau de bord. Les résultats utilisés pour ajuster et évaluer le modèle sont, eux, séparés entre apprentissage et test. Les écarts viennent donc des périmètres de calcul utilisés dans les différentes étapes et restent de quelques millièmes.

Captures du tableau de bord Power BI

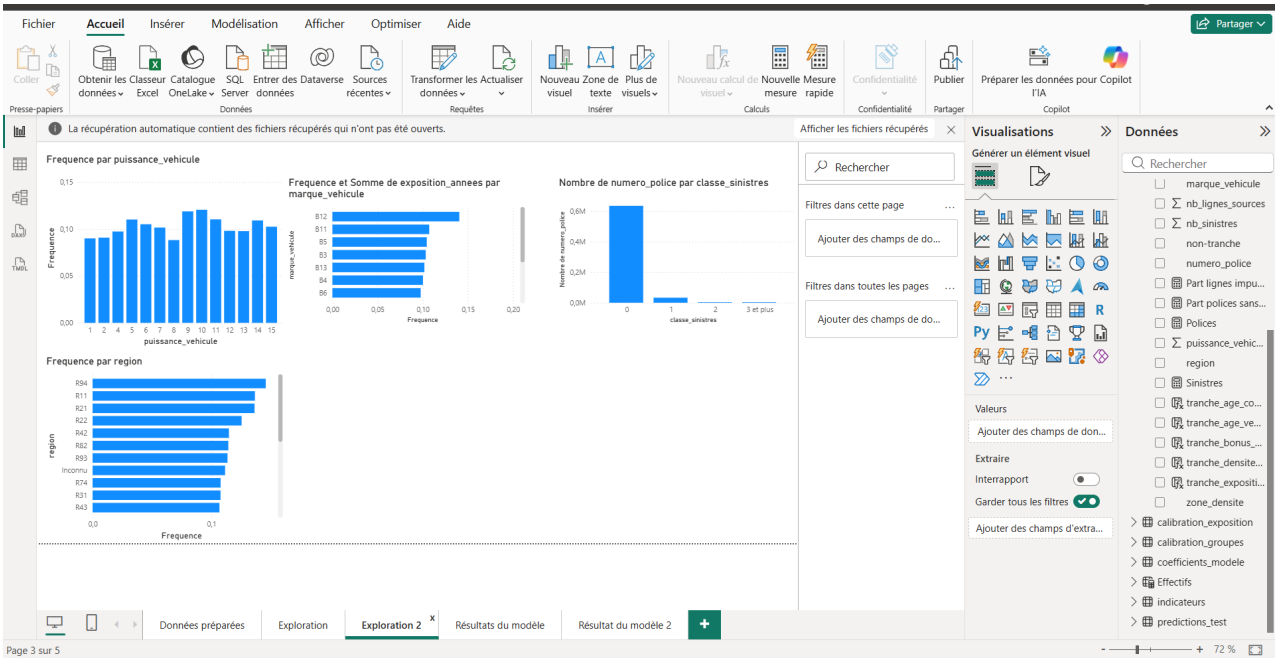
Page « Données préparées »



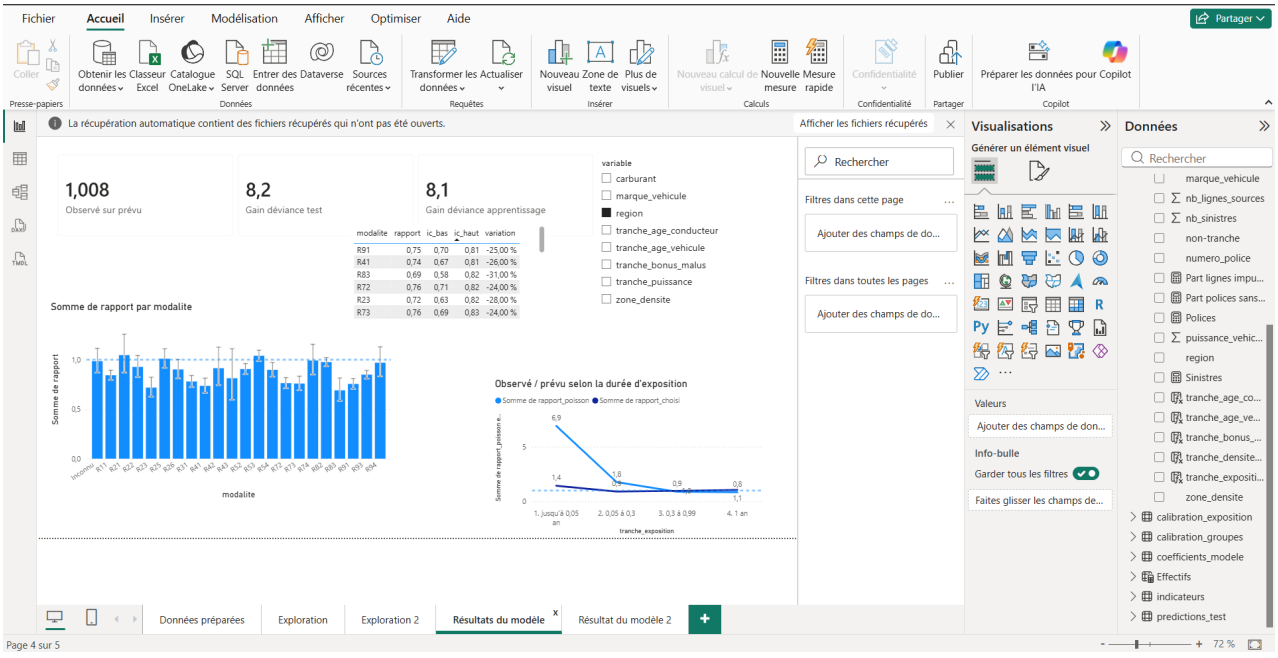
Page « Exploration »



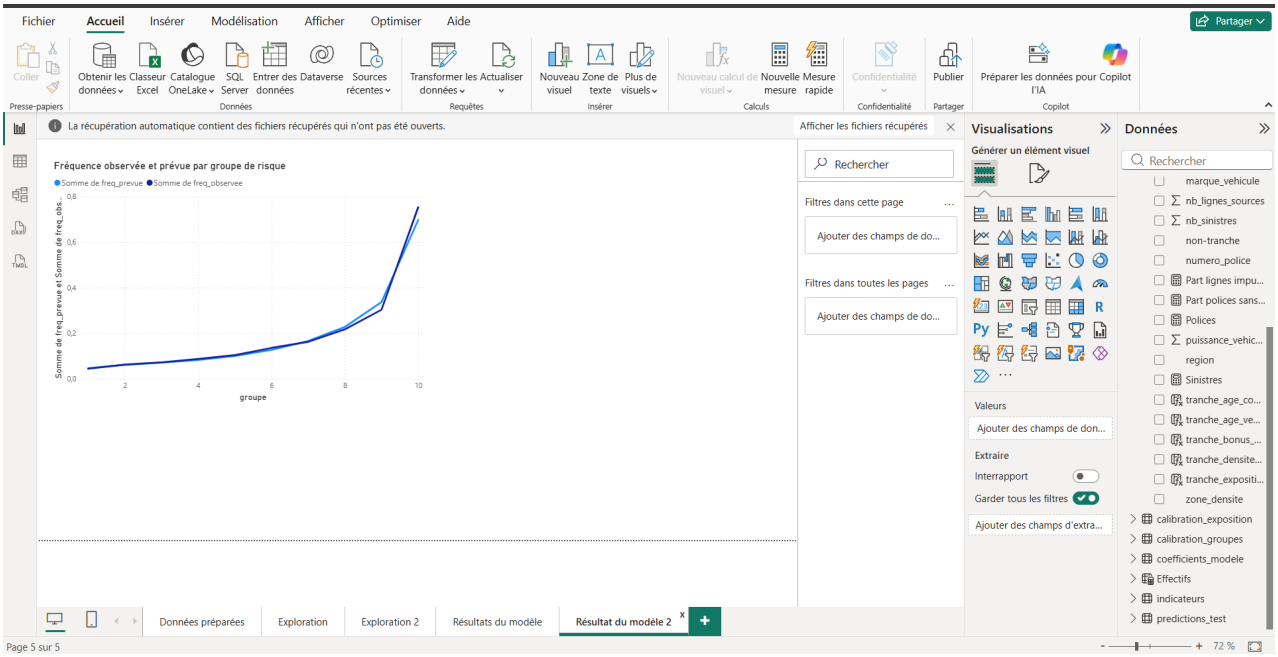
Page « Exploration 2 »



Page « Résultats du modèle »



Page « Résultat du modèle 2 »



9. Ce que ce travail ne dit pas

Je préfère être clair sur les limites de ce travail.

- Je modélise la fréquence seulement, pas le coût des sinistres. Je n'ai donc pas de prime.
- Mon test est tiré au hasard. Je ne peux pas vérifier la stabilité dans le temps, car les données ne contiennent aucune date.
- 14,1 % des lignes ont au moins une valeur imputée par la médiane, surtout le bonus-malus (médiane à 50, la meilleure classe). Les résultats restent stables sans ces lignes (écart maximal de 4,6 %).
- Les exclusions faites au nettoyage (expositions supérieures à 1, polices à plus de 5 sinistres) influencent le niveau de fréquence.
- Le coefficient de log(exposition) corrige une anomalie des données. Il n'a pas de sens d'assurance. Il rend aussi les groupes de risque sensibles à la durée d'observation (partie 5).
- Les groupes 6, 9 et 10 sont moins bien calés (écarts de 6 à 11 %).
- log(exposition) ne corrige pas entièrement les contrats de moins de 0,05 an : le modèle y sous-estime encore les sinistres de 35 % sur le test (partie 5). Ces contrats pourraient être traités à part.
- Un sinistre est un événement rare et en partie aléatoire. Le gain de déviance reste modeste (8 %). Le modèle sert surtout à classer les risques.
- La fusion des polices (1 411 cas) reste un point ouvert : ces lignes sont peut-être une ligne d'origine et une copie modifiée. Le test de la partie 7 montre que cela ne change presque rien.

Ce que je retiens

Le modèle que je retiens est une binomiale négative avec log(exposition), sur 8 variables. Il est bien calé sur le test (observé / prévu de 1,008) et les gains de déviance sont proches entre le test (8,2 %) et l'apprentissage (8,1 %), sans écart important entre les deux. Il classe bien les polices : la fréquence est 17 fois plus élevée dans le groupe le plus risqué que dans le moins risqué.

Les principaux facteurs de risque sont le bonus-malus (jusqu'à 4,7 fois plus de sinistres à 101 et plus), l'âge du véhicule (2,4 fois plus pour un véhicule neuf) et l'âge du conducteur. La zone, la puissance, la région, la marque et le carburant ont des effets plus faibles. Et les résultats restent stables quand on retire les lignes imputées ou fusionnées.

Si je devais retenir une seule leçon, ce serait celle-ci : le plus gros gain du projet n'est pas venu d'un modèle plus sophistiqué, mais d'avoir remarqué qu'une hypothèse de départ (les sinistres proportionnels à la durée) ne tenait pas dans les données.

Les tables pour le tableau de bord Power BI sont exportées dans le dossier sorties_modele/ (partie 8).

Annexe : tous les effets

Rapport de fréquence, avec l'intervalle de confiance à 95 % entre crochets.

Variable	Modalité	Rapport	IC 95 %
Âge conducteur	18-21	0,973	[0,890 ; 1,065]
Âge conducteur	22-25	0,745	[0,696 ; 0,796]
Âge conducteur	26-30	0,642	[0,608 ; 0,677]
Âge conducteur	31-40	0,743	[0,715 ; 0,771]
Âge conducteur	41-50	1,022	[0,988 ; 1,057]
Âge conducteur	71 et +	1,151	[1,092 ; 1,213]
Âge véhicule	0 an	2,355	[2,255 ; 2,460]
Âge véhicule	1-3 ans	0,892	[0,861 ; 0,924]
Âge véhicule	11-15 ans	0,851	[0,821 ; 0,882]
Âge véhicule	16 ans et +	0,647	[0,610 ; 0,687]
Bonus-malus	51-60	1,264	[1,213 ; 1,317]
Bonus-malus	61-80	1,754	[1,691 ; 1,820]
Bonus-malus	81-100	2,085	[1,992 ; 2,182]
Bonus-malus	101 et +	4,716	[4,379 ; 5,079]
Zone	A	0,917	[0,879 ; 0,957]
Zone	B	0,970	[0,927 ; 1,015]
Zone	D	1,092	[1,054 ; 1,132]
Zone	E	1,099	[1,058 ; 1,143]
Zone	F	1,177	[1,078 ; 1,285]
Zone	Inconnu	1,049	[0,841 ; 1,310]
Puissance	4 et moins	0,827	[0,793 ; 0,863]
Puissance	5	0,991	[0,953 ; 1,030]
Puissance	7	0,932	[0,897 ; 0,968]
Puissance	8	0,760	[0,715 ; 0,808]
Puissance	9-10	1,070	[1,018 ; 1,124]
Puissance	11 et +	0,888	[0,831 ; 0,949]
Carburant	Diesel	0,916	[0,891 ; 0,941]
Carburant	Inconnu	0,898	[0,808 ; 0,998]
Marque	B10	0,982	[0,898 ; 1,073]
Marque	B11	1,035	[0,939 ; 1,140]
Marque	B12	1,039	[0,996 ; 1,084]
Marque	B13	1,060	[0,963 ; 1,167]
Marque	B14	0,814	[0,670 ; 0,988]
Marque	B2	0,992	[0,956 ; 1,030]
Marque	B3	0,995	[0,944 ; 1,048]
Marque	B4	1,002	[0,933 ; 1,075]
Marque	B5	1,076	[1,013 ; 1,142]
Marque	B6	0,955	[0,891 ; 1,023]
Marque	Inconnu	0,988	[0,914 ; 1,068]

Variable	Modalité	Rapport	IC 95 %
Région	Inconnu	0,984	[0,869 ; 1,115]
Région	R11	0,843	[0,795 ; 0,893]
Région	R21	1,046	[0,870 ; 1,259]
Région	R22	0,927	[0,824 ; 1,043]
Région	R23	0,718	[0,626 ; 0,824]
Région	R25	1,009	[0,917 ; 1,111]
Région	R26	0,901	[0,810 ; 1,003]
Région	R31	0,780	[0,723 ; 0,840]
Région	R41	0,736	[0,665 ; 0,814]
Région	R42	0,914	[0,742 ; 1,126]
Région	R43	0,813	[0,595 ; 1,111]
Région	R52	0,905	[0,853 ; 0,961]
Région	R53	1,040	[0,986 ; 1,097]
Région	R54	0,897	[0,829 ; 0,972]
Région	R72	0,763	[0,711 ; 0,819]
Région	R73	0,759	[0,691 ; 0,834]
Région	R74	0,991	[0,850 ; 1,156]
Région	R82	0,976	[0,933 ; 1,020]
Région	R83	0,690	[0,584 ; 0,816]
Région	R91	0,755	[0,705 ; 0,808]
Région	R93	0,849	[0,808 ; 0,892]
Région	R94	0,969	[0,831 ; 1,130]
log(exposition)	coefficient	0,551	[0,543 ; 0,559]